

Revisao de Classificacao das Tabelas Historicas MCMV

Documento de evidencias de dados para a issue #96, com auditoria pandas, tabelas de controle, hashes e registros de amostra.

FRENTE

Cidades - Dados Historicos

BRANCH

feat/tratamento-dados-historicos

METODO

pandas + inventario + dedup + relatorios

FEATURE

#53 - Inteligencia preditiva MCMV

DATA

2026-07-07

ENTREGA

HTML/PDF + CSVs de evidencia

Sumario Executivo

A revisao consolidou os CSVs de classificacao, qualidade, inventario, deduplicacao e amostras reais do PostgreSQL. Foram corrigidas seis tabelas para **separador pipe**, incluindo o falso descarte de `tab_arquivos_dados`.

754

REGISTROS AUDITADOS

0

CONFIDENCE=LOW


6


CORRIGIDAS ISSUE #96

6

PRINTS REAIS DB

Ponto de controle: a branch atual nao contem `data/table_samples/`, entao as seis divergencias foram comprovadas por consulta DB com pandas. O PDF traz print bruto e print apos split por pipe.





Resultado Consolidado

Categoria	Quantidade
bem_formada	351
sub_tabelas_1	273
cabecalho_composto_2	50
cabecalho_na_primeira_linha_1	36
sub_tabelas_3	19
separador_pipe	6
cabecalho_composto_1	4
dados_sem_utilidade	3
sem_cabecalho	3
vazia	2
cabecalho_na_segunda_linha	2
sub_tabelas_2	1
cabecalho_na_primeira_linha_2	1
cabecalho_na_terceira_linha_2	1
cabecalho_na_terceira_linha_1	1
sub_tabelas_4	1

Flags de revisao geradas pelo pandas

Flag	Quantidade
qualidade_vs_inventario	100
corrigida_issue96	6
classificacao_vs_inventario	2

Leitura: as flags restantes indicam principalmente diferencas entre inventario e qualidade/tratamento, em especial erros de persistencia por limite de identificador no PostgreSQL. Elas nao alteram a classificacao estrutural revisada da issue #96.

Tabelas Corrigidas

Tabela	Classificacao final	Confianca	Inventario	Linhas	Colunas	Status qualidade	Perfil qualia
bb_2013_06_junho_pmcmv_18062013_tab_andamento_obras	separador pipe	high	separador pipe	1022	17	treated	separ
bb_2013_06_junho_pmcmv_18062013_tab_arquivos_dados	separador pipe	high	separador pipe	2	6	treated	separ
bb_2013_06_junho_pmcmv_18062013_tab_caracterizacoes_entornos	separador pipe	high	separador pipe	292	16	treated	separ
bb_2013_06_junho_pmcmv_18062013_tab_contratos_pj	separador pipe	high	separador pipe	596	4	treated	separ
bb_2013_06_junho_pmcmv_18062013_tab_proponentes	separador pipe	high	separador pipe	526	4	treated	separ
bb_2013_06_junho_pmcmv_18062013_tab_unidades_concluidas	separador pipe	high	separador pipe	1374	7	treated	separ

Disponibilidade das amostras brutas

Tabela	Caminho esperado
bb_2013_06_junho_pmcmv_18062013_tab_andamento_obras	/home/juan-pablo/CIDADES/data-application-cidades/data-science/dados-historicos-tratamento/data/table_samples/bb_2013_06_junho_pmcmv_18062013_tab_andamento_
bb_2013_06_junho_pmcmv_18062013_tab_arquivos_dados	/home/juan-pablo/CIDADES/data-application-cidades/data-science/dados-historicos-tratamento/data/table_samples/bb_2013_06_junho_pmcmv_18062013_tab_arquivos_da
bb_2013_06_junho_pmcmv_18062013_tab_caracterizacoes_entornos	/home/juan-pablo/CIDADES/data-application-cidades/data-science/dados-historicos-tratamento/data/table_samples/bb_2013_06_junho_pmcmv_18062013_tab_caracterizaci
bb_2013_06_junho_pmcmv_18062013_tab_contratos_pj	/home/juan-pablo/CIDADES/data-application-cidades/data-science/dados-historicos-tratamento/data/table_samples/bb_2013_06_junho_pmcmv_18062013_tab_contratos_pj
bb_2013_06_junho_pmcmv_18062013_tab_proponentes	/home/juan-pablo/CIDADES/data-application-cidades/data-science/dados-historicos-tratamento/data/table_samples/bb_2013_06_junho_pmcmv_18062013_tab_proponentes
bb_2013_06_junho_pmcmv_18062013_tab_unidades_concluidas	/home/juan-pablo/CIDADES/data-application-cidades/data-science/dados-historicos-tratamento/data/table_samples/bb_2013_06_junho_pmcmv_18062013_tab_unidades_cc

Erro e Correcao Comprovados

Tabela	Classificacao antes	Status antes	Classificacao corrigida	Status corrigido	Linhas corrigidas	Colun pos-split
bb_2013_06_junho_pmcmv_18062013_tab_andamento_obras	vazia	discarded	separador_]	treated	1022	17
bb_2013_06_junho_pmcmv_18062013_tab_arquivos_dados	dados_sem_utilidade	discarded	separador_]	treated	2	6
bb_2013_06_junho_pmcmv_18062013_tab_caracterizacoes_entornos	vazia	discarded	separador_]	treated	292	16
bb_2013_06_junho_pmcmv_18062013_tab_contratos_pj	vazia	discarded	separador_]	treated	596	4
bb_2013_06_junho_pmcmv_18062013_tab_proponentes	vazia	discarded	separador_]	treated	526	4
bb_2013_06_junho_pmcmv_18062013_tab_unidades_concluidas	vazia	discarded	separador_]	treated	1374	7

A evidencia acima foi salva em `correcoes_classificacao_db_pandas.csv`. Ela mostra a classificacao anterior, a classificacao corrigida, a quantidade de linhas brutas e quantas colunas surgem apos o split por pipe.

Print Real da Amostra DB

Print pandas real da tabela bb_2013_06_junho_pmcnv_18062013_tab_arquivos_dados. O primeiro bloco mostra o erro estrutural: valores com | dentro de uma unica coluna. O segundo bloco mostra a correcao esperada: expansao por separador pipe.

Antes: amostra bruta

```
datacnpj_bbresp_arqtel_resp_arqe_mail_resp_arqdata_pos_arq
2013-06-17|00000000|CARLOS THIAGO DE AGUIAR NOGUEIRA GO...
2013-06-17|00000000|CARLOS THIAGO DE AGUIAR NOGUEIRA GO...
```

Depois: split por pipe

```
      campo_1  campo_2      campo_3  campo_4      campo_5  campo_6
2013-06-17  00000000 CARLOS THIAGO DE AGUIAR NOGUE... 6131026187 c.thiago.gomes@bb.com.br 2013-06-17
2013-06-17  00000000 CARLOS THIAGO DE AGUIAR NOGUE... 6131026187 c.thiago.gomes@bb.com.br 2013-06-17
```

Evidencia de nao duplicidade

As seis tabelas corrigidas compartilham formacao estrutural, mas os hashes e tamanhos no _dedup_map sao diferentes. Portanto, elas nao foram tratadas como conteudo identico.

Artefatos Gerados com Pandas

Arquivo	Conteúdo
auditoria_classificacao_completa_pandas.csv	754 linhas cruzando classificacao, inventario, qualidade, dedup e flags.
flags_revisao_pandas.csv	106 linhas com pontos de atencao para revisoes futuras.
correcoes_classificacao_pandas.csv	Antes/depois das classificacoes corrigidas.
correcoes_qualidade_pandas.csv	Antes/depois do status de qualidade das tabelas corrigidas.
correcoes_inventario_pandas.csv	Antes/depois do inventario para comprovar persistencia da correcao.
correcoes_classificacao_db_pandas.csv	Evidencia DB do erro e da correcao proposta para as seis tabelas pipe.
amostras_pipe_db_pandas.csv	Prints reais do banco antes e depois do split por pipe.
amostras_disponibilidade_pandas.csv	Comprovacao de ausencia das amostras brutas locais e fontes fallback.

Resumo para resposta da issue

Foi executada auditoria pandas nos CSVs de controle e nas amostras DB. As seis tabelas divergentes foram corrigidas para separador pipe; os snapshots ficaram sem linhas `confidence=low`, e `tab_arquivos_dados` deixou de ser falso descarte.