

Revisao de Classificacao das Tabelas Historicas MCMV

Documento de evidencias de dados para a issue #96, com auditoria pandas, tabelas de controle, hashes e registros de amostra.

FRENTE

Cidades - Dados Historicos

BRANCH

feat/tratamento-dados-historicos

METODO

pandas + inventario + dedup + relatorios

FEATURE

#53 - Inteligencia preditiva MCMV

DATA

2026-07-07

ENTREGA

HTML/PDF + CSVs de evidencia

Sumario Executivo

A revisao consolidou os CSVs de classificacao, qualidade, inventario e deduplicacao. As cinco divergencias criticas de baixa confianca foram corrigidas para **separador pipe**, com evidencias cruzadas em inventario, dedup e relatorio de tratamento.

754

REGISTROS AUDITADOS

0

CONFIDENCE=LOW

5

CORRIGIDAS ISSUE #96

0

AMOSTRAS BRUTAS
LOCAIS

Ponto de controle: a branch atual nao contem data/table_samples/. Portanto, esta entrega comprova a auditoria completa dos CSVs de controle com pandas e evidencia versionada. A varredura linha a linha dos CSVs brutos deve ser reexecutada quando as amostras forem disponibilizadas ou via modo DB.

Distribuicao revisada por categoria estrutural





Figura 1 - Distribuicao revisada das categorias estruturais.



Resultado Consolidado

Categoria	Quantidade
bem_formada	351
sub_tabelas_1	273
cabecalho_composto_2	50
cabecalho_na_primeira_linha_1	36
sub_tabelas_3	19
separador_pipe	5
cabecalho_composto_1	4
dados_sem_utilidade	4
sem_cabecalho	3
vazia	2
cabecalho_na_segunda_linha	2
sub_tabelas_2	1
cabecalho_na_primeira_linha_2	1
cabecalho_na_terceira_linha_2	1
cabecalho_na_terceira_linha_1	1
sub_tabelas_4	1

Flags de revisao geradas pelo pandas

Flag	Quantidade
qualidade_vs_inventario	100
corrigida_issue96	5
classificacao_vs_inventario	2

Leitura: as flags restantes indicam principalmente diferencas entre inventario e qualidade/tratamento, em especial erros de persistencia por limite de identificador no PostgreSQL. Elas nao alteram a classificacao estrutural revisada da issue #96.

Tabelas Corrigidas

Tabela	Classificacao final	Confianca	Inventario	Linhas	Colunas	Status qualidade	Perfil qualifi
bb_2013_06_junho_pmcmv_18062013_tab_andamento_obras	separador pipe	high	separador pipe	200	21	treated	separ
bb_2013_06_junho_pmcmv_18062013_tab_caracterizacoes_entornos	separador pipe	high	separador pipe	146	20	treated	separ
bb_2013_06_junho_pmcmv_18062013_tab_contratos_pj	separador pipe	high	separador pipe	200	8	treated	separ
bb_2013_06_junho_pmcmv_18062013_tab_proponentes	separador pipe	high	separador pipe	200	8	treated	separ
bb_2013_06_junho_pmcmv_18062013_tab_unidades_concluidas	separador pipe	high	separador pipe	200	11	treated	separ

Disponibilidade das amostras brutas

Tabela	Caminho esperado
bb_2013_06_junho_pmcmv_18062013_tab_andamento_obras	/home/juan-pablo/CIDADES/data-application-cidades/data-science/dados-historicos-tratamento/data/table_samples/bb_2013_06_junho_pmcmv_18062013_tab_andamento_
bb_2013_06_junho_pmcmv_18062013_tab_caracterizacoes_entornos	/home/juan-pablo/CIDADES/data-application-cidades/data-science/dados-historicos-tratamento/data/table_samples/bb_2013_06_junho_pmcmv_18062013_tab_caracterizaco
bb_2013_06_junho_pmcmv_18062013_tab_contratos_pj	/home/juan-pablo/CIDADES/data-application-cidades/data-science/dados-historicos-tratamento/data/table_samples/bb_2013_06_junho_pmcmv_18062013_tab_contratos_pj
bb_2013_06_junho_pmcmv_18062013_tab_proponentes	/home/juan-pablo/CIDADES/data-application-cidades/data-science/dados-historicos-tratamento/data/table_samples/bb_2013_06_junho_pmcmv_18062013_tab_proponentes
bb_2013_06_junho_pmcmv_18062013_tab_unidades_concluidas	/home/juan-pablo/CIDADES/data-application-cidades/data-science/dados-historicos-tratamento/data/table_samples/bb_2013_06_junho_pmcmv_18062013_tab_unidades_cc

Print Real de Amostra Versionada

O print abaixo vem de `data/exemplos_por_categoria.md`, arquivo versionado do proprio pipeline. Ele demonstra a estrutura de **separador pipe**: uma coluna com valores contendo |.

```
Dimensoes: 200 linhas x 1 coluna
Coluna: cod_operacaocod_sit_obracod_re
```

0	23157	0 0 0		2013-04-30
1	27175	6 0 0		2011-09-13
2	29302	0 0 0		2010-07-05
3	29350	6 0 0		2012-06-08
4	29536	2 0 0		2013-01-10

Evidencia de nao duplicidade

As cinco tabelas corrigidas compartilham formacao estrutural, mas os hashes e tamanhos no `_dedup_map` sao diferentes. Portanto, elas nao foram tratadas como conteudo identico.

Artefatos Gerados com Pandas

Arquivo	Conteúdo
auditoria_classificacao_completa_pandas.csv	754 linhas cruzando classificacao, inventario, qualidade, dedup e flags.
flags_revisao_pandas.csv	105 linhas com pontos de atencao para revisoes futuras.
correcoes_classificacao_pandas.csv	Antes/depois das classificacoes corrigidas.
correcoes_qualidade_pandas.csv	Antes/depois do status de qualidade das tabelas corrigidas.
amostras_disponibilidade_pandas.csv	Comprovacao de ausencia das amostras brutas locais e fontes fallback.

Resumo para resposta da issue

Foi executada auditoria pandas nos CSVs de controle. As cinco tabelas divergentes foram corrigidas para separador pipe; os snapshots ficaram sem linhas `confidence=low`. A inspecao linha a linha dos brutos depende de disponibilizar `data/table_samples/` ou acesso DB.