

MINISTERIO DAS CIDADES | MINHA CASA MINHA VIDA

Revisao de Tratamento de Dados Historicos MCMV

Auditoria tecnica com pandas, evidencias de qualidade e recomendacoes para analise preditiva.

Data: 2026-07-07 | Fonte: /home/juan-pablo/CIDADES/data-application-cidades/data-science/dados-historicos-tratamento

Sumario Executivo

TABELAS REVISADAS	STATUS TREATED	CSVs TRATADOS ENCONTRADOS
395	356 (90.1%)	0
FLAGS DE REVISAO	ERROS	DESCARTES
158	34	5

Veredito: Parcialmente tratados, ainda nao aprovados para uso preditivo final.

O snapshot de qualidade indica que 356 de 395 tabelas (90.1%) chegaram a status treated. Isso mostra que o pipeline processa a maior parte do acervo, mas os 34 erros, 5 descartes e 158 linhas com flags impedem uma aprovacao final sem ajustes e sem os CSVs tratados.

O que parece bom: a maior parte do snapshot de qualidade esta como treated (356/395), com perfis majoritariamente colunares e relatorio de deduplicacao disponivel.


O que ainda nao esta bom: ha 34 erros, 158 linhas com flags, 23 erros de identificador longo, metadados temporais/institucionais ausentes e nenhuma pasta data/treated_tables para provar o dado final linha a linha.

Distribuicao de status

status	quantidade
treated	356
error	34
discarded	5

Flags por tipo

flag	quantidade
report_date_missing	132
institution_unknown	92
zero_rows	39
zero_cols	39
status_error	34
status_discarded	5
missing_gt_30	4



Evidencias de Problemas

Principais Flags

table_name	status	rows	cols	profile	missing_pct	institution	report_date	flag_revisao	error
001_2011_08_agosto_prev isao_de_conclusao_e_entr ega_far_modelo	tre ate d	71	15	colun ar_de nso	4.78873 2394366 197	unk now n	2011 -08- 01	institution_unknown;	
001_2012_02_fevereiro_b ase_pmcvm_relatorio_exe cutivo_10_02_2012	err or	0	0	sub_t abela s_1	0.0			status_error;zero_rows;zer o_cols;institution_unknown; report_date_missing;	Identifier '_001_2012_02_fevereiro_base_pmcvm_rela torio_executivo_10_02_2012' exceeds maximum length of 63 characters
001_2012_10_outubro_20 121009_bases_relatorio_e xecutivo_0910201	tre ate d	182 44	40	colun ar_de nso	4.99287 4369655 778	unk now n	2012 -10- 01	institution_unknown;	
001_2012_10_outubro_20 121009_bases_relatorio_e xecutivo_1610201	tre ate d	183 52	40	colun ar_de nso	4.99318 8753269 399	unk now n	2012 -10- 01	institution_unknown;	
011_12_dezembro_pmcvm _relatorio_executivo_3112 2011_base___copi	tre ate d	703 2	14	colun ar_de nso	7.14285 7142857 142	unk now n		institution_unknown;report_ date_missing;	
018_int040_ministeriocida des_far_caixa_empreendi mentos_20181001	err or	0	0	bem_f ormad a	0.0			status_error;zero_rows;zer o_cols;institution_unknown; report_date_missing;	Identifier '_018_int040_ministeriocidades_far_caixa_e mpreendimentos_20181001' exceeds maximum length of 63 characters
024_10_snh_pmcvm_dado s_prioritarios_da_entrega_ da_unidade_af_bb	err or	0	0	bem_f ormad a	0.0			status_error;zero_rows;zer o_cols;institution_unknown; report_date_missing;	Identifier '_024_10_snh_pmcvm_dados_prioritarios_da _entrega_da_unidade_af_bb' exceeds maximum length of 63 characters
1_2018_int054_ministerioc idades_far_bb_empreendi mentos_20180831	err or	0	0	bem_f ormad a	0.0			status_error;zero_rows;zer o_cols;institution_unknown; report_date_missing;	Identifier '_1_2018_int054_ministeriocidades_far_bb_e mpreendimentos_20180831' exceeds maximum length of 63 characters
202402_snh_pmcvm_dado s_prioritarios_da_entrega_ da_unidade_af_bb	err or	0	0	bem_f ormad a	0.0			status_error;zero_rows;zer o_cols;institution_unknown; report_date_missing;	Identifier '_202402_snh_pmcvm_dados_prioritarios_da _entrega_da_unidade_af_bb' exceeds maximum length of 63 characters
202406_snh_pmcvm_dado s_prioritarios_da_entrega_ da_unidade_af_bb	err or	0	0	bem_f ormad a	0.0			status_error;zero_rows;zer o_cols;institution_unknown; report_date_missing;	Identifier '_202406_snh_pmcvm_dados_prioritarios_da _entrega_da_unidade_af_bb' exceeds maximum length of 63 characters
202407_snh_pmcvm_dado s_prioritarios_da_entrega_ da_unidade_af_bb	err or	0	0	bem_f ormad a	0.0			status_error;zero_rows;zer o_cols;institution_unknown; report_date_missing;	Identifier '_202407_snh_pmcvm_dados_prioritarios_da _entrega_da_unidade_af_bb' exceeds maximum length of 63 characters
202408_snh_pmcvm_dado s_prioritarios_da_entrega_ da_unidade_af_bb	err or	0	0	bem_f ormad a	0.0			status_error;zero_rows;zer o_cols;institution_unknown; report_date_missing;	Identifier '_202408_snh_pmcvm_dados_prioritarios_da _entrega_da_unidade_af_bb' exceeds maximum length of 63 characters
202409_snh_pmcvm_dado s_prioritarios_da_entrega_ da_unidade_af_bb	err or	0	0	bem_f ormad a	0.0			status_error;zero_rows;zer o_cols;institution_unknown; report_date_missing;	Identifier '_202409_snh_pmcvm_dados_prioritarios_da _entrega_da_unidade_af_bb' exceeds maximum length of 63 characters
202411_snh_pmcvm_dado s_prioritarios_da_entrega_ da_unidade_af_bb	err or	0	0	bem_f ormad a	0.0			status_error;zero_rows;zer o_cols;institution_unknown; report_date_missing;	Identifier '_202411_snh_pmcvm_dados_prioritarios_da _entrega_da_unidade_af_bb' exceeds maximum length of 63 characters
202412_snh_pmcvm_dado s_prioritarios_da_entrega_ da_unidade_af_bb	err or	0	0	bem_f ormad a	0.0			status_error;zero_rows;zer o_cols;institution_unknown; report_date_missing;	Identifier '_202412_snh_pmcvm_dados_prioritarios_da _entrega_da_unidade_af_bb' exceeds maximum length of 63 characters
202501_snh_pmcvm_dado s_prioritarios_da_entrega_ da_unidade_af_bb	err or	0	0	bem_f ormad a	0.0			status_error;zero_rows;zer o_cols;institution_unknown; report_date_missing;	Identifier '_202501_snh_pmcvm_dados_prioritarios_da _entrega_da_unidade_af_bb' exceeds maximum length of 63 characters

table_name	status	rows	ncols	profile	missing_pct	institution	report_date	flag_revisao	error
202503_snh_pmcmmv_dados_prioritarios_da_entrega_da_unidade_af_bb	error	0	0	benchmark	0.0			status_error;zero_rows;zero_cols;institution_unknown;report_date_missing;	Identifier '_202503_snh_pmcmmv_dados_prioritarios_da_entrega_da_unidade_af_bb' exceeds maximum length of 63 characters
202504_snh_pmcmmv_dados_prioritarios_da_entrega_da_unidade_af_bb	error	0	0	benchmark	0.0			status_error;zero_rows;zero_cols;institution_unknown;report_date_missing;	Identifier '_202504_snh_pmcmmv_dados_prioritarios_da_entrega_da_unidade_af_bb' exceeds maximum length of 63 characters
202505_snh_pmcmmv_dados_prioritarios_da_entrega_da_unidade_af_bb	error	0	0	benchmark	0.0			status_error;zero_rows;zero_cols;institution_unknown;report_date_missing;	Identifier '_202505_snh_pmcmmv_dados_prioritarios_da_entrega_da_unidade_af_bb' exceeds maximum length of 63 characters
202506_snh_pmcmmv_dados_prioritarios_da_entrega_da_unidade_af_bb	error	0	0	benchmark	0.0			status_error;zero_rows;zero_cols;institution_unknown;report_date_missing;	Identifier '_202506_snh_pmcmmv_dados_prioritarios_da_entrega_da_unidade_af_bb' exceeds maximum length of 63 characters
202507_snh_pmcmmv_dados_prioritarios_da_entrega_da_unidade_af_bb	error	0	0	benchmark	0.0			status_error;zero_rows;zero_cols;institution_unknown;report_date_missing;	Identifier '_202507_snh_pmcmmv_dados_prioritarios_da_entrega_da_unidade_af_bb' exceeds maximum length of 63 characters
202508_snh_pmcmmv_dados_prioritarios_da_entrega_da_unidade_af_bb	error	0	0	benchmark	0.0			status_error;zero_rows;zero_cols;institution_unknown;report_date_missing;	Identifier '_202508_snh_pmcmmv_dados_prioritarios_da_entrega_da_unidade_af_bb' exceeds maximum length of 63 characters
202509_snh_pmcmmv_dados_prioritarios_da_entrega_da_unidade_af_bb	error	0	0	benchmark	0.0			status_error;zero_rows;zero_cols;institution_unknown;report_date_missing;	Identifier '_202509_snh_pmcmmv_dados_prioritarios_da_entrega_da_unidade_af_bb' exceeds maximum length of 63 characters
202510_snh_pmcmmv_dados_prioritarios_da_entrega_da_unidade_af_bb	error	0	0	benchmark	0.0			status_error;zero_rows;zero_cols;institution_unknown;report_date_missing;	Identifier '_202510_snh_pmcmmv_dados_prioritarios_da_entrega_da_unidade_af_bb' exceeds maximum length of 63 characters
202511_snh_pmcmmv_dados_prioritarios_da_entrega_da_unidade_af_bb	error	0	0	benchmark	0.0			status_error;zero_rows;zero_cols;institution_unknown;report_date_missing;	Identifier '_202511_snh_pmcmmv_dados_prioritarios_da_entrega_da_unidade_af_bb' exceeds maximum length of 63 characters
202602_snh_pmcmmv_dados_prioritarios_da_entrega_da_unidade_af_bb	error	0	0	benchmark	0.0			status_error;zero_rows;zero_cols;institution_unknown;report_date_missing;	Identifier '_202602_snh_pmcmmv_dados_prioritarios_da_entrega_da_unidade_af_bb' exceeds maximum length of 63 characters
202603_snh_pmcmmv_dados_prioritarios_da_entrega_da_unidade_af_bb	error	0	0	benchmark	0.0			status_error;zero_rows;zero_cols;institution_unknown;report_date_missing;	Identifier '_202603_snh_pmcmmv_dados_prioritarios_da_entrega_da_unidade_af_bb' exceeds maximum length of 63 characters
_001_2012_01_janeiro_pmcmmv_relatorio_executivo_31012012_base_bd	treated	8208	14	columnar_denso	0.0	unknown	2012-01-01	institution_unknown;	
_001_2012_04_abril_2012_04_18_5c_base_contratacao_pf_18042012	treated	33914	23	columnar_denso	2.760947768139873	unknown	2012-04-01	institution_unknown;	
_001_2012_11_novembro_sintese_20121128_evento_1_milhao_entregas	treated	48	12	sub_tables_2	28.819444444443	unknown	2012-11-01	institution_unknown;	

Maiores missing_pct

table_name	status	rows	ncols	profile	missing_pct	institution	report_date	flag_revisao
mbro_2009_relatorio_automatizado_31dez09final_com_base_valor_mc	treated	43	13	sub_tables_3	45.97495527728086	unknown		missing_gt_30;institution_unknown;report_date_missing;
caixa_001_2009_10_outubro_2009_pmcmmv_08_10_2009__caixa	treated	23	13	sub_tables_3	36.78929765886287	caixa	2009-10-01	missing_gt_30;
caixa_001_2009_12_dezembro_2009_pmcmmv_24_12_2009_parte2	treated	19013	18	columnar_denso	31.38174465424242	caixa	2009-12-01	missing_gt_30;
caixa_001_2010_08__agosto_2010_municipios_contratados_1308	treated	58	13	sub_tables_3	30.76923076923077	caixa	2010-08-01	missing_gt_30;
_001_2012_11_novembro_sintese_20121128_evento_1_milhao_entregas	treated	48	12	sub_tables_2	28.819444444443	unknown	2012-11-01	institution_unknown;

table_name	status	n_rows	n_cols	profile	missing_pct	institution	report_date	flag_revisao
historico_recente_202409_snh_pmcmv_dados_prioritarios_af_caixa	treated	24922	30	colunar_denso	24.02535912045582	unknown		institution_unknown;report_date_missing;
historico_recente_202411_snh_pmcmv_dados_prioritarios_af_bb	treated	2576	41	colunar_denso	23.420693834267535	unknown		institution_unknown;report_date_missing;
historico_recente_202407_snh_pmcmv_dados_prioritarios_af_caixa	treated	24452	30	colunar_denso	21.501172364905393	unknown		institution_unknown;report_date_missing;
historico_recente_2025_01_snh_pmcmv_dados_prioritarios_af_bb	treated	2576	41	colunar_denso	20.97598848659294	unknown	2025-01-01	institution_unknown;
historico_recente_202509_snh_pmcmv_dados_prioritarios_af_bb	treated	2576	39	colunar_denso	19.612995699952222	unknown		institution_unknown;report_date_missing;
historico_recente_202507_snh_pmcmv_dados_prioritarios_af_bb	treated	2576	39	colunar_denso	19.603041885650583	unknown		institution_unknown;report_date_missing;
historico_recente_202508_snh_pmcmv_dados_prioritarios_af_bb	treated	2576	39	colunar_denso	19.5970695970696	unknown		institution_unknown;report_date_missing;

Evidencias e Lacunas

O que nao foi encontrado nesta branch

- data/treated_tables/ nao existe nesta branch; nao foi possivel abrir CSV tratado linha a linha.
- diff_sftp_minio*.json nao foi encontrado nesta branch/worktree; impacto SFTP detalhado ficou pendente.
- amostras_tratadas_pandas.csv registra ausencia de amostras tratadas para prints reais.

Amostra pandas

Nenhum CSV tratado encontrado em data/treated_tables/.

Impacto SFTP/MinIO

artefato	tipo	registros	added	removed	modified	unchanged	same_size_false	container_mapped	erro
----------	------	-----------	-------	---------	----------	-----------	-----------------	------------------	------

Recomendacoes

- Localizar ou regenerar data/treated_tables/ para validar linha a linha nomes, datas, valores, encoding e tipos nos CSVs finais.
- Corrigir os erros de identificador longo no writer/tratamento, pois 23 dos 34 erros indicam limite de 63 caracteres.
- Revisar extracao de report_date e institution; ha 132 flags de report_date ausente e 92 de institution desconhecida.
- Auditar as 4 tabelas com missing_pct acima de 30% para separar esparsidade real de tratamento excessivo.
- Trazer os diff_sftp_minio*.json para confirmar impacto de path, zip, duplicidade e filename no tratamento.

Arquivos gerados

- /home/juan-pablo/CIDADES/data-application-cidades/data-science/dados-historicos-tratamento/docs/evidencias/revisao-tratamento-dados/auditoria_tratamento_pandas.csv
- /home/juan-pablo/CIDADES/data-application-cidades/data-science/dados-historicos-tratamento/docs/evidencias/revisao-tratamento-dados/flags_tratamento_pandas.csv
- /home/juan-pablo/CIDADES/data-application-cidades/data-science/dados-historicos-tratamento/docs/evidencias/revisao-tratamento-dados/amostras_tratadas_pandas.csv
- /home/juan-pablo/CIDADES/data-application-cidades/data-science/dados-historicos-tratamento/docs/evidencias/revisao-tratamento-dados/impacto_sftp_tratamento_pandas.csv

