

MINISTERIO DAS CIDADES | MINHA CASA MINHA VIDA

Revisao de Tratamento de Dados Historicos MCMV

Auditoria tecnica com pandas, evidencias de qualidade e recomendacoes para analise preditiva.

Data: 2026-07-07 | Fonte: /home/juan-pablo/CIDADES/data-application-cidades/data-science/dados-historicos-tratamento

Sumario Executivo

FONTE Banco	TABELAS QUALIDADE 395	STATUS TREATED 385 (97.5%)
ERROS 0	DESCARTES 10	DISCORDANCIAS LIDAS 35

Veredito: Tratamento sem erros no banco, mas ainda com discordancias a corrigir antes do uso preditivo final.

A leitura do banco em dados_historicos_formatados mostra 385 de 395 registros de qualidade com status treated (97.5%), 10 descartes e 0 erros. A aprovacao final depende de corrigir as 35 discordancias amostradas: 13 tabelas com missing_pct > 30%, 80 com instituicao desconhecida, 99 com report_date ausente e descartes pipe com dados estruturaveis.

O que parece bom: a maior parte da qualidade esta como treated (385/395) e o banco formatado nao apresentou status error na leitura atual.


O que ainda nao esta bom: ha discordancias com evidencia: missing alto, metadados temporais/institucionais ausentes e descartes pipe com dado bruto estruturavel.

Distribuicao de status

status	quantidade
treated	356
error	34
discarded	5

Flags por tipo

flag	quantidade
missing_alto	13
metadados_incompletos	12
descarte_incorreto_pipe	6
descarte_revisar	4



Evidencias de Problemas

Principais Flags

table_name	status	profile	missing_pct	motivo_discordancia	evidencia	como_consertar	treated_exists	raw_exists
bb_2011_01_janeiro_rel_25jan2011	treated	sub_tabelas_3	71.88189845474614	missing_alto	missing_pct=71.88% em tabela sub_tabelas_3; risco de subtabelas esparsas ou colunas mantidas em excesso.	Revisar extracao de subtabelas, remover colunas vazias/rodapes ou transformar blocos em formato longo antes do uso preditivo.	True	True
bb_2011_02_fevereiro_relatorio_mcmv_bb_08_02_2011	treated	sub_tabelas_3	71.82671081677704	missing_alto	missing_pct=71.83% em tabela sub_tabelas_3; risco de subtabelas esparsas ou colunas mantidas em excesso.	Revisar extracao de subtabelas, remover colunas vazias/rodapes ou transformar blocos em formato longo antes do uso preditivo.	True	True
bb_2011_02_fevereiro_relatorio_mcmv_bb_16_02_2011	treated	sub_tabelas_3	71.78991905813098	missing_alto	missing_pct=71.79% em tabela sub_tabelas_3; risco de subtabelas esparsas ou colunas mantidas em excesso.	Revisar extracao de subtabelas, remover colunas vazias/rodapes ou transformar blocos em formato longo antes do uso preditivo.	True	True
bb_2011_03_marco_relatorio_min_cidades_22mar11	treated	sub_tabelas_3	66.77107571147306	missing_alto	missing_pct=66.77% em tabela sub_tabelas_3; risco de subtabelas esparsas ou colunas mantidas em excesso.	Revisar extracao de subtabelas, remover colunas vazias/rodapes ou transformar blocos em formato longo antes do uso preditivo.	True	True
bb_2011_04_abril_relatorio_min_cidades_18abr11	treated	sub_tabelas_3	66.28781098979775	missing_alto	missing_pct=66.29% em tabela sub_tabelas_3; risco de subtabelas esparsas ou colunas mantidas em excesso.	Revisar extracao de subtabelas, remover colunas vazias/rodapes ou transformar blocos em formato longo antes do uso preditivo.	True	True
bb_2011_05_maio_relatorio_min_cidades_24mai11	treated	sub_tabelas_3	66.28781098979775	missing_alto	missing_pct=66.29% em tabela sub_tabelas_3; risco de subtabelas esparsas ou colunas mantidas em excesso.	Revisar extracao de subtabelas, remover colunas vazias/rodapes ou transformar blocos em formato longo antes do uso preditivo.	True	True
bb_2011_05_maio_relatorio_min_cidades_10mai11	treated	sub_tabelas_3	66.28781098979775	missing_alto	missing_pct=66.29% em tabela sub_tabelas_3; risco de subtabelas esparsas ou colunas mantidas em excesso.	Revisar extracao de subtabelas, remover colunas vazias/rodapes ou transformar blocos em formato longo antes do uso preditivo.	True	True
bb_2011_06_junho_relatorio_min_cidades_07jun11	treated	sub_tabelas_3	65.42867370681941	missing_alto	missing_pct=65.43% em tabela sub_tabelas_3; risco de subtabelas esparsas ou colunas mantidas em excesso.	Revisar extracao de subtabelas, remover colunas vazias/rodapes ou transformar blocos em formato longo antes do uso preditivo.	True	True
bb_2011_07_julho_relatorio_min_cidades_19jul11	treated	sub_tabelas_3	65.19599069267944	missing_alto	missing_pct=65.20% em tabela sub_tabelas_3; risco de subtabelas esparsas ou colunas mantidas em excesso.	Revisar extracao de subtabelas, remover colunas vazias/rodapes ou transformar blocos em formato longo antes do uso preditivo.	True	True
bb_2011_01_janeiro_rel_11jan2011	treated	sub_tabelas_3	64.29820179820179	missing_alto	missing_pct=64.30% em tabela sub_tabelas_3; risco de subtabelas esparsas ou colunas mantidas em excesso.	Revisar extracao de subtabelas, remover colunas vazias/rodapes ou transformar blocos em formato longo antes do uso preditivo.	True	True
mbro_2009_relatorio_automatizado_31dez09final_com_base_valor_mc	treated	sub_tabelas_3	57.98319327731093	missing_alto	missing_pct=57.98% em tabela sub_tabelas_3; risco de subtabelas esparsas ou colunas mantidas em excesso.	Revisar extracao de subtabelas, remover colunas vazias/rodapes ou transformar blocos em formato longo antes do uso preditivo.	True	True
caixa_001_2009_12_dezembro_2009_pmc_mv_24_12_2009_parte2	treated	colunar_denso	31.38174465424242	missing_alto	missing_pct=31.38% em tabela colunar_denso; risco de subtabelas esparsas ou colunas mantidas em excesso.	Revisar extracao de subtabelas, remover colunas vazias/rodapes ou transformar blocos em formato longo antes do uso preditivo.	True	True
caixa_001_2012_07_julho_bases_relatorio_executivo_24_07_12	treated	sub_tabelas_4	30.056818181818183	missing_alto	missing_pct=30.06% em tabela sub_tabelas_4; risco de subtabelas esparsas ou colunas mantidas em excesso.	Revisar extracao de subtabelas, remover colunas vazias/rodapes ou transformar blocos em formato longo antes do uso preditivo.	True	True
caixa_001_2015_datas_entregas_pj_mcmv_30062015	treated	lookup	16.666666666666664	metadados_incompletos	Tabela tratada, mas institution/report_date incompletos enfraquecem linhagem temporal e uso preditivo.	Estender inferir_instituicao() e extrair_periodo_filename() com padroes dessas tabelas; adicionar teste de regressao.	True	True
caixa_001_2016_grafico_mcmv_31082016	treated	sub_tabelas_3	14.285714285714285	metadados_incompletos	Tabela tratada, mas institution/report_date incompletos enfraquecem linhagem temporal e uso preditivo.	Estender inferir_instituicao() e extrair_periodo_filename() com padroes dessas tabelas; adicionar teste de regressao.	True	True
caixa_002_2018_bext_ago18	treated	colunar_denso	3.7037037037	metadados_incompletos	Tabela tratada, mas institution/report_date incompletos	Estender inferir_instituicao() e extrair_periodo_filename() com padroes	True	True

table_name	status	profile	missing_pct	motivo_discordancia	evidencia	como_consertar	treated_exists	raw_exists
	d		037033	ompletos	enfraquecem linhagem temporal e uso preditivo.	dessas tabelas; adicionar teste de regressao.		
caixa_002_2018_bext_jun18	treated	colunar_denso	3.7037 037037 037033	metadados_incompletos	Tabela tratada, mas institution/report_date incompletos enfraquecem linhagem temporal e uso preditivo.	Estender inferir_instituicao() e extrair_periodo_filename() com padroes dessas tabelas; adicionar teste de regressao.	True	True
caixa_002_2018_bext_mai18	treated	colunar_denso	3.7037 037037 037033	metadados_incompletos	Tabela tratada, mas institution/report_date incompletos enfraquecem linhagem temporal e uso preditivo.	Estender inferir_instituicao() e extrair_periodo_filename() com padroes dessas tabelas; adicionar teste de regressao.	True	True
caixa_002_2018_bext_abr18	treated	colunar_denso	3.7037 037037 037033	metadados_incompletos	Tabela tratada, mas institution/report_date incompletos enfraquecem linhagem temporal e uso preditivo.	Estender inferir_instituicao() e extrair_periodo_filename() com padroes dessas tabelas; adicionar teste de regressao.	True	True
caixa_002_2018_bext_mar18	treated	colunar_denso	3.7037 037037 037033	metadados_incompletos	Tabela tratada, mas institution/report_date incompletos enfraquecem linhagem temporal e uso preditivo.	Estender inferir_instituicao() e extrair_periodo_filename() com padroes dessas tabelas; adicionar teste de regressao.	True	True
caixa_002_2017_bext_dez17	treated	colunar_denso	3.7037 037037 037033	metadados_incompletos	Tabela tratada, mas institution/report_date incompletos enfraquecem linhagem temporal e uso preditivo.	Estender inferir_instituicao() e extrair_periodo_filename() com padroes dessas tabelas; adicionar teste de regressao.	True	True
caixa_003_2017_bext_out2017	treated	colunar_denso	3.7037 037037 037033	metadados_incompletos	Tabela tratada, mas institution/report_date incompletos enfraquecem linhagem temporal e uso preditivo.	Estender inferir_instituicao() e extrair_periodo_filename() com padroes dessas tabelas; adicionar teste de regressao.	True	True
caixa_002_2017_bext_ago2017	treated	colunar_denso	3.7037 037037 037033	metadados_incompletos	Tabela tratada, mas institution/report_date incompletos enfraquecem linhagem temporal e uso preditivo.	Estender inferir_instituicao() e extrair_periodo_filename() com padroes dessas tabelas; adicionar teste de regressao.	True	True
caixa_003_2017_bext_mai2017	treated	colunar_denso	3.7037 037037 037033	metadados_incompletos	Tabela tratada, mas institution/report_date incompletos enfraquecem linhagem temporal e uso preditivo.	Estender inferir_instituicao() e extrair_periodo_filename() com padroes dessas tabelas; adicionar teste de regressao.	True	True
caixa_002_2017_bext_abr2017	treated	colunar_denso	3.7037 037037 037033	metadados_incompletos	Tabela tratada, mas institution/report_date incompletos enfraquecem linhagem temporal e uso preditivo.	Estender inferir_instituicao() e extrair_periodo_filename() com padroes dessas tabelas; adicionar teste de regressao.	True	True
bb_2013_06_junho_p_mcmv_18062013_tab_andamento_obras	discarded	vazia	0	descarte_incorreto_pip	Tabela foi descartada como vazia/dados_sem_utilidade, mas a amostra bruta tem registros pipe-delimited; ha dados estruturaveis.	Corrigir classificacao para separador_], reprocessar com tratar_separador_pipe(), e adicionar teste cobrindo esta familia de tabelas tab_.*.	False	True
bb_2013_06_junho_p_mcmv_18062013_tab_arquivos_dados	discarded	dados_sem_utilidade	0	descarte_incorreto_pip	Tabela foi descartada como vazia/dados_sem_utilidade, mas a amostra bruta tem registros pipe-delimited; ha dados estruturaveis.	Corrigir classificacao para separador_], reprocessar com tratar_separador_pipe(), e adicionar teste cobrindo esta familia de tabelas tab_.*.	False	True
bb_2013_06_junho_p_mcmv_18062013_tab_caracterizacoes_entornos	discarded	vazia	0	descarte_incorreto_pip	Tabela foi descartada como vazia/dados_sem_utilidade, mas a amostra bruta tem registros pipe-delimited; ha dados estruturaveis.	Corrigir classificacao para separador_], reprocessar com tratar_separador_pipe(), e adicionar teste cobrindo esta familia de tabelas tab_.*.	False	True
bb_2013_06_junho_p_mcmv_18062013_tab_contratos_pj	discarded	vazia	0	descarte_incorreto_pip	Tabela foi descartada como vazia/dados_sem_utilidade, mas a amostra bruta tem registros pipe-delimited; ha dados estruturaveis.	Corrigir classificacao para separador_], reprocessar com tratar_separador_pipe(), e adicionar teste cobrindo esta familia de tabelas tab_.*.	False	True
bb_2013_06_junho_p_mcmv_18062013_tab_proponentes	discarded	vazia	0	descarte_incorreto_pip	Tabela foi descartada como vazia/dados_sem_utilidade, mas a amostra bruta tem registros pipe-delimited; ha dados estruturaveis.	Corrigir classificacao para separador_], reprocessar com tratar_separador_pipe(), e adicionar teste cobrindo esta familia de tabelas tab_.*.	False	True
bb_2013_06_junho_p_mcmv_18062013_tab_unidades_concluidas	discarded	vazia	0	descarte_incorreto_pip	Tabela foi descartada como vazia/dados_sem_utilidade, mas a amostra bruta tem registros pipe-delimited; ha dados estruturaveis.	Corrigir classificacao para separador_], reprocessar com tratar_separador_pipe(), e adicionar teste cobrindo esta familia de tabelas tab_.*.	False	True
bb_2015_03_marco_cgu_of_6263_tab_em_p_20150831	discarded	vazia	0	descarte_revisar	Tabela descartada precisa ter justificativa estrutural verificavel.	Confirmar se a categoria e vazia/dados_sem_utilidade; caso tenha dado util, ajustar regra de descarte.	False	True

table_name	status	profile	missing_pct	motivo_discordancia	evidencia	como_consertar	treated_exists	raw_exists
bb_2015_08_agosto_loginfesta	discarded	dados_sem_utilidade	0	descarte_revisar	Tabela descartada precisa ter justificativa estrutural verificavel.	Confirmar se a categoria e vazia/dados_sem_utilidade; caso tenha dado util, ajustar regra de descarte.	False	True
caixa_001_2016_bext_31102016	discarded	vazia	0	descarte_revisar	Tabela descartada precisa ter justificativa estrutural verificavel.	Confirmar se a categoria e vazia/dados_sem_utilidade; caso tenha dado util, ajustar regra de descarte.	False	True
caixa_002_2018_novo_relatorio_executivo	discarded	dados_sem_utilidade	0	descarte_revisar	Tabela descartada precisa ter justificativa estrutural verificavel.	Confirmar se a categoria e vazia/dados_sem_utilidade; caso tenha dado util, ajustar regra de descarte.	False	True

Maiores missing_pct

table_name	status	n_rows	n_cols	profile	missing_pct	institution	report_date
bb_2011_01_janeiro_rel_25jan2011	treated	302	36	sub_tabelas_3	71.88189845474614	bb	2011-01-01
bb_2011_02_fevereiro_relatorio_mcmv_bb_08_02_2011	treated	302	36	sub_tabelas_3	71.82671081677704	bb	2011-02-08
bb_2011_02_fevereiro_relatorio_mcmv_bb_16_02_2011	treated	302	36	sub_tabelas_3	71.78991905813098	bb	2011-02-16
bb_2011_03_marco_relatorio_min_cidades__22mar11	treated	302	37	sub_tabelas_3	66.77107571147306	bb	2011-03-01
bb_2011_04_abril_relatorio_min_cidades__18abr11	treated	302	37	sub_tabelas_3	66.28781098979775	bb	2011-04-01
bb_2011_05_maio_relatorio_min_cidades__24mai11	treated	302	37	sub_tabelas_3	66.28781098979775	bb	2011-05-01
bb_2011_05_maio_relatorio_min_cidades__10mai11	treated	302	37	sub_tabelas_3	66.28781098979775	bb	2011-05-01
bb_2011_06_junho_relatorio_min_cidades__07jun11	treated	302	37	sub_tabelas_3	65.42867370681941	bb	2011-06-01
bb_2011_07_julho_relatorio_min_cidades_19jul11	treated	302	37	sub_tabelas_3	65.19599069267944	bb	2011-07-01
bb_2011_01_janeiro_rel_11jan2011	treated	308	26	sub_tabelas_3	64.29820179820179	bb	2011-01-01
mbro_2009_relatorio_automatizado_31dez09final_com_base_valor_mc	treated	49	17	sub_tabelas_3	57.98319327731093	unknown	
caixa_001_2009_12_dezembro_2009_pmcvmv_24_12_2009_parte2	treated	19013	18	colunar_densio	31.38174465424242	caixa	2009-12-01

Evidencias e Lacunas

O que nao foi encontrado nesta branch

- data/treated_tables/ nao existe no repo, mas as amostras foram lidas diretamente do schema dados_historicos_formatados.
- diff_sftp_minio*.json nao foi encontrado nesta branch/worktree; impacto SFTP detalhado ficou pendente.
- amostras_tratadas_pandas.csv registra ausencia de amostras tratadas para prints reais.

Amostra DB: missing_alto - bb_2011_01_janeiro_rel_25jan2011

Evidencia: missing_pct=71.88% em tabela sub_tabelas_3; risco de subtabelas esparsas ou colunas mantidas em excesso.

Como consertar: Revisar extracao de subtabelas, remover colunas vazias/rodapes ou transformar blocos em formato longo antes do uso preditivo.

Tabela tratada

```
contratacao_total contratacao_total_1 contratacao_total_2 contratacao_total_3 contratacao_total_4 contratacao_total_5 ...
valor_total_aprovado_cef valor_total_desligamento source_table report_date institution profile
...
bb_2011_01_janeiro_rel_25jan2011 2011-01-01 bb colunar_denso
bb_2011_01_janeiro_rel_25jan2011 2011-01-01 bb colunar_denso
bb_2011_01_janeiro_rel_25jan2011 2011-01-01 bb colunar_denso
bb_2011_01_janeiro_rel_25jan2011 2011-01-01 bb colunar_denso
bb_2011_01_janeiro_rel_25jan2011 2011-01-01 bb colunar_denso
bb_2011_01_janeiro_rel_25jan2011 2011-01-01 bb colunar_denso
bb_2011_01_janeiro_rel_25jan2011 2011-01-01 bb colunar_denso
bb_2011_01_janeiro_rel_25jan2011 2011-01-01 bb colunar_denso
bb_2011_01_janeiro_rel_25jan2011 2011-01-01 bb colunar_denso
```

Tabela bruta

```
unnamed_0 relatório_01_total_das_contratações_por_ufregião_geográfic unnamed_2 unnamed_3
unnamed_4 unnamed_5 ... unnamed_11 unnamed_12 unnamed_13
unnamed_14 unnamed_15 unnamed_16
... Aprovado CEF - Financ à Produção PJ e R... Desligamento - Plano Piloto Contratação total
Disponíveis Total Financ PF ... UF Quantidade unidades Unid Financ PF Unid
% Meta R$ Quantidade unidades Valor Total Financ PF Total Financ à Produção PJ Meta R$
0 ... 20000000 0
144 ... 2784445.29 44188348.41 116690000
0.37868153577855856
120 ... 120 53000000
0
48 ... 0 0 0
312 0 ... Centro Oeste 2784445.29 44188348.41 189690000 0
0.23295033164637038 0 0
0 ... AL 0 0 0
```

Amostra DB: metadados_incompletos - caixa_001_2015_datas_entregas_pj_mcmv_30062015

Evidencia: Tabela tratada, mas institution/report_date incompletos enfraquecem linhagem temporal e uso preditivo.

Como consertar: Estender inferir_instituicao() e extrair_periodo_filename() com padroes dessas tabelas; adicionar teste de regressao.

Tabela tratada

Tabela bruta

Amostra DB: descarte_incorreto_pipe -
bb_2013_06_junho_pmcmv_18062013_tab_andamento_obras

Como consertar: Corrigir classificacao para separador_, reprocessar com tratar_separador_pipe(), e adicionar teste cobrindo esta familia de tabelas tab *.

Tabela nao encontrada.

```
cod_operacao cod_sit obracod regime construcaocod pendencia obra  
23157|0|0|0|||2013-04-30|2010-12-28...  
27175|6|0|0|||2011-09-13|2011-08-03...  
29302|0|0|0|||2010-07-05|0,00|0,00...  
29350|6|0|0|||2012-06-08|2011-04-26...  
29536|2|0|0|||2013-01-10|2012-05-29...  
32374|0|0|0|||2013-04-02|2011-03-04...  
52036|0|0|0|||2013-06-13|2011-10-11...  
56015|0|0|0|||2013-06-13|2011-08-03...
```

artefato	tipo	registros	added	removed	modified	unchanged	same_size_false	container_mapped	erro
----------	------	-----------	-------	---------	----------	-----------	-----------------	------------------	------

- Corrigir 6 descartes pipe: alinhar classificacao para separador_| e reprocessar com tratar_separador_pipe().
- Revisar 13 tabelas com missing alto, principalmente sub_tabelas_3: separar blocos, remover colunas vazias e avaliar formato longo para features.
- Corrigir 12 casos amostrados de metadados: ampliar extrair_periodo_filename() para datas como 25jan2011, 22mar11 e 31dez09.
- Revisar 4 descartes restantes para confirmar se sao de fato vazios/sem utilidade.
- Adicionar testes de regressao para familias bb_2011_relatorio_min_cidades, datas_entregas_pj e bb_2013_06_junho_pmcvmv_18062013_tab *.

- /home/juan-pablo/CIDADES/data-application-cidades/data-science/dados-historicos-tratamento/docs/evidencias/revisao-tratamento-dados/auditoria_tratamento_pandas.csv
- /home/juan-pablo/CIDADES/data-application-cidades/data-science/dados-historicos-tratamento/docs/evidencias/revisao-tratamento-dados/flags_tratamento_pandas.csv
- /home/juan-pablo/CIDADES/data-application-cidades/data-science/dados-historicos-tratamento/docs/evidencias/revisao-tratamento-dados/amostas tratadas pandas.csv

- [/home/juan-pablo/CIDADES/data-application-cidades/data-science/dados-historicos-tratamento/docs/evidencias/revisao-tratamento-dados/impacto_sftp_tratamento_pandas.csv](#)

